مساعد Qwen المحلي

تقرير فني لمراجعة كود المشروع وتقديمه للدكتور

31 أكتوبر 2026 • النسخة المستقرة للعرض (الملف الأصلي المرفق) • الحالة: نموذج أولي

1 | الملخص التنفيذي

وصل ملف البرنامج الأساسي gui_chat_rag.py، وتمت مقارنته مع نسختي gui_chat_v2.py وgui_chat_rag_v2.py. نوصي بتقديم gui_chat_rag.py بوصفه الملف الأساسي الأقرب للواجهة المستقرة المعروضة على المنفذ 8508: فهو يحتوي على واجهة المحادثة ودعم PDF والبحث الدلالي وإظهار المصادر، ولا يحمل تسمية «اختبار تحسين البحث» الظاهرة في النسخة التجريبية. لا نستطيع الجزم من مراجعة الملف وحدها بأن العملية على 8508 تستخدم الملف نفسه؛ يتطلب ذلك الاطلاع على أمر التشغيل في جهاز المطور.

2 | مقارنة النسخ المستلمة

الملف	وصف الوظيفة	قرار التسليم
gui_chat_rag.py — 432 سطرًا	Qwen 3.5، PDF، RAG، محادثات ومصادر	الملف الأساسي للعرض
gui_chat_v2.py — 118 سطرًا	محادثة Qwen 2.5 فقط، بلا RAG	مرجع تاريخي اختياري
gui_chat_rag_v2.py — 517 سطرًا	نسخة اختبار تحسين البحث	مرجع تجريبي، لا يُعرض

3 | المكونات والتسلسل

Python وStreamlit للواجهة؛ PyMuPDF لقراءة النص من ملفات PDF؛ LangChain لتنظيم رسائل النموذج وسلسلة الاستدعاء؛ Ollama لتشغيل Qwen 3.5 9B محليًا؛ BGE-M3 لتحويل مقاطع الملفات والأسئلة إلى متجهات. يتم ترتيب نتائج الاسترجاع بتشابه جيب التمام (Cosine Similarity)، ثم إرسال أفضل المقاطع إلى Qwen ليصيغ إجابة.

PDF → استخراج النص مع أرقام الصفحات → مقاطع طولها 900 حرف وتداخل 150 → **BGE-M3** → حساب التشابه مع السؤال → أفضل 6 مقاطع → **Qwen** → إجابة مع مصادر.

4 | إمكانات مثبتة في الكود

- المحادثات بالعربية مع سجل محفوظ في ملف JSON محلي، وإمكانية إنشاء محادثات متعددة.
- رفع أكثر من ملف PDF نصي وفهرسة المقاطع مع حفظ اسم الملف ورقم الصفحة.
- معاينة من الصفحة الثانية، وإظهار المقاطع المسترجعة وأرقام الصفحات داخل الواجهة.
- تشغيل النموذج اللغوي والتضمينات محليًا عبر Ollama دون وجود استدعاء ظاهر لمزود نماذج سحابية.

5 | حدود التحقق والملاحظات

- نجح فحص الصياغة النحوية (Python AST) للملفات الثلاثة. هذا فحص للكود المرفق وليس اختبار تشغيل Qwen أو Ollama في جهاز المستخدم.
- لم تكشف مراجعة أنماط المفاتيح الشائعة عن سر API صريح في الملفات الثلاثة؛ لكنه فحص محدود ولا يضمن خلو كل ملفات جهاز المطور من معلومات خاصة.
- تستخرج المكتبة نص PDF فقط؛ الملفات التي تتكون من صور ضوئية بدون نص لا يوجد لها OCR مدمج في الكود.
- المصادر المعروضة هي مقاطع مسترجعة؛ قد لا تكون كل مقاطع الاسترجاع كافية لدعم كامل الإجابة، لذا يحتاج التوثيق إلى تحقق بشري.
- الفهرسة والتضمينات تستعمل الذاكرة والتخزين المؤقت للتطبيق؛ لا توجد قاعدة بيانات متجهية خارجية أو تدريب/ضبط دقيق لQwen.
- ملفات المحادثات الشخصية و.env وملفات المحاضرات الأصلية ليست ضمن حزمة المشاركة احترامًا للخصوصية والحقوق.

6 | التشغيل المقترح في جلسة العرض

يتطلب تشغيل Ollama ووجود النموذجين بالمعرّفين qwen3.5:9b-q4_K_M وbge-m3. ثبّت الحزم المدرجة في requirements.txt، ثم نفّذ الأمر التالي من مجلد النسخة الأساسية:

python -m streamlit run gui_chat_rag.py --server.port 8508

في الواجهة: رفع PDF نصي → انتظار نجاح الفهرسة → سؤال عن RNN → فتح «المصادر المسترجعة لهذا السؤال». الحزمة لا تتضمن أوزان النموذج، ولذلك يلزم تجهيز بيئة جهاز العرض مسبقًا.

7 | أسئلة مختصرة قد يطرحها الدكتور

س: هل دربت **Qwen** بنفسك؟

ج: لا. استخدمت نموذجًا جاهزًا محليًا، وربطته بتقنية RAG لاستخراج المعلومات من PDF.

س: ما دور **BGE-M3**؟

ج: إنشاء تمثيلات متجهية لمقاطع النص والسؤال للبحث الدلالي.

س: هل يعمل بدون الإنترنت؟

ج: عند توفر النماذج والمكتبات مثبتة محليًا، يمكن تنفيذ الاستدلال محليًا؛ تنزيل المتطلبات ابتداءً يحتاج اتصالًا.

س: هل الإجابات موثوقة 100%؟

ج: لا. المراجع تساعد على المراجعة، وما زال المشروع نموذجًا أوليًا ويحتاج اختبارات دقة.

8 | قرار المراجعة

يمكن إرسال حزمة المراجعة الأكاديمية الآن مع توضيح أن ملف التشغيل المقصود هو **gui_chat_rag.py** الأصلي غير المعدل، وأن النسخ الأخرى مراجع فقط. يُفضَّل التأكد من أمر تشغيل المنفذ 8508 قبل بدء العرض أمام الدكتور، دون أي تعديل للكود.